


인도 중고차 시장 마케팅 차별화 전략 BIG DATA PROJECT - 1

포스코 빅데이터 AI 아카데미 32기
A4조: 김성준 (조장), 조수원, 박정현, 김어진, 박예인




Project Definition

인도 자동차 시장 조사



인도 자동차 시장은 2030년 약 8.4백만 대까지 성장할 것으로 예상.
승용차의 비중이 가장 크게 증가

<FY 2023 국가별 승용차 보유율(인구 대비 비중)>
(단위: %)




주요 국가 대비 차량 보유율 매우 낮음 (3%)
중고차 시장 성장 가능성 매우 높음.

현재, 인도에서 자동차 수요는 높아 시장으로 진입하기에 좋은 환경이다.

인도/차량의 어떤 점을 주목해야 하는가? - 파생변수 생성 근거/계획

Average New Car Depreciation



차량은 시간이 지날수록 감가상각이 발생하여
가치가 지속적으로 감소하는 특성이 존재

The South Buys Newer. The North Holds Longer

Cars24

Regional Distribution

North & Central India


- Higher share of 2017-2019 and pre-2017 vehicles
- Indicates longer ownership cycles

West India

- Balanced mix across 2017-2021
- Stable resale churn

South India

- Higher concentration of 2020+ vehicles
- Newer cars contribute meaningfully to transactions



Insight

- Southern markets show a higher concentration of 2020 and newer vehicles, indicating faster upgrade cycles and higher car adoption.
- Western India displays a more balanced resale mix across 2017 - 2021 model years, suggesting stable ownership churn.
- North and Central India have a greater share of pre-2019 vehicles, pointing to longer ownership cycles and value driven resale behaviour.
- These variations underline how regional economics and buyer preferences directly impact inventory age profiles.

09

인도는 동/서/남/북 모두 문화가 다르며
주목해야할 시장과 고려요소가 많음.

1. 파생변수 생성

차량의 연식(year)을 활용하여 car_age 파생변수를 생성하고 차량
연령대를 구간화하여 분석에 활용한다.

2. 가격 중심 분석 / 모델링 선정

가격(price)을 기준으로 차량 특성 변수(주행거리, 엔진, 파워 등)에
대해 유의성 검증 및 확인의 최적 모델 도출

3. 변수 조합 기반 인사이트 도출


최적의 모델에서 핵심중요인자를 선별하여 분석

4. 분석 결과 기반 마케팅 전략 도출


도출된 분석 결과를 바탕으로 지역별 차량 판매 전략 및 마케팅 방향
에 대한 인사이트를 제시한다.

따라서 **차량의 연식과 인도의 지역적 특성**를 모두 고려하는 파생변수를 생성해야 하며, 이를 중점으로 해석하여 차별적인 마케팅 전략을 계획한다.

Project Plan



1. 데이터 특성 파악 및 전처리
2. 인코딩 & 파생변수 설정
3. 모델링 
4. Best Model 선정
5. 핵심인자 추출
6. Insight



EDA-1. 데이터셋 파악

```
RangeIndex: 7253 entries, 0 to 7252
Data columns (total 13 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Name                   7253 non-null   object
1   Location               7253 non-null   object
2   Price                  6200 non-null   float64
3   Year                   7253 non-null   int64
4   Kilometers_Driven      7253 non-null   int64
5   Fuel_Type              7253 non-null   object
6   Transmission           7253 non-null   object
7   Owner_Type             7253 non-null   object
8   Mileage                7251 non-null   object
9   Engine                 7207 non-null   object
10  Power                  7207 non-null   object
11  Seats                  7200 non-null   float64
12  New_Price              1006 non-null   object
dtypes: float64(2), int64(2), object(9)
```

7253 rows x 13 columns

목표변수

- Price: 중고차 가격 (단위: 1,000원) -연속형

설명변수

- Name: 자동차의 브랜드와 모델 이름 -범주형
- Location: 자동차를 팔거나 구매할 수 있는 위치 -범주형
- Year: 모델의 연도 혹은 버전 -연속형
- Kilometers_Driven: 이전 소유주의 차량 주행거리 (km) -연속형
- Fuel_Type: 자동차의 사용 연료의 종류 -범주형
- Transmission: 자동차의 사용 변속기의 종류 -범주형
- Owner_Type: 소유권이 직접 소유인지 중고 소유인지 여부 -범주형
- Mileage: 자동차 회사가 제공하는 표준형 연비 (kmpl) -연속형
- Engine: 엔진의 배기량 (cc) -연속형
- Power: 엔진의 최대 출력 (bhp) -연속형
- Seats: 차의 좌석 수 -연속형
- New_Price: 새 모델의 가격 -연속형



EDA-2. 데이터셋 분포 확인

연속형 변수

	min	max	missing
Price	7.08	245273.60	1053
Year	1996.00	2019.00	0
Kilometers_Driven	171.00	6500000.00	0
Mileage	0.00	33.54	2
Engine	72.00	5998.00	46
Power	34.20	488.10	2789
Seats	0.00	10.00	53

Price와 Kilometers_Driven는 값의 범위가 매우 넓음.

Mileage, Engine, Power, Seats 에는 일부 결측치가 존재

범주형 변수


	Count	Percent(%)
Fuel_Type		
Diesel	3852	53.11
Petrol	3325	45.84
CNG	62	0.85

고른 분포

==== Transmission (Top 5) ====		
	Count	Percent(%)
Transmission		
Manual	5204	71.75
Automatic	2049	28.25

데이터 한 개의 비중이 큼

==== Location (Top 5) ====		
	Count	Percent(%)
Location		
Mumbai	949	13.08
Hyderabad	876	12.08
Coimbatore	772	10.64
Kochi	772	10.64
Pune	765	10.55



고른 분포

	Count	Percent(%)
Owner_Type		
First	5952	82.06
Second	1152	15.88
Third	137	1.89

데이터 한 개의 비중이 큼

Missing Value Handling

결측치 처리

```
RangeIndex: 7253 entries, 0 to 7252
Data columns (total 13 columns):
#   Column          Non-Null Count  Dtype
---  -
0   Name             7253 non-null   object
1   Location          7253 non-null   object
2   Price            6200 non-null   float64
3   Year             7253 non-null   int64
4   Kilometers_Driven 7253 non-null   int64
5   Fuel_Type        7253 non-null   object
6   Transmission      7253 non-null   object
7   Owner_Type       7253 non-null   object
8   Mileage          7251 non-null   object
9   Engine           7207 non-null   object
10  Power            7207 non-null   object
11  Seats            7200 non-null   float64
12  New_Price        1006 non-null   object
dtypes: float64(2), int64(2), object(9)
```

```
Name          0
Location       0
Price         1053
Year           0
Kilometers_Driven 0
Fuel_Type      0
Transmission   0
Owner_Type     0
Mileage        2
Engine         46
Power          46
Seats          53
New_Price      6247
dtype: int64
```

1) 제거

- Price는 목표변수이기에 결측치 제거
- New Price 결측치가 많아(86%) 제거
- Mileage 결측치가 소수이기에(0.002%) 제거
- Seats수가 0인 행 (1개) 제거

2) 보완

동일한 차량 모델(Name)의 경우 차량 제원이 동일하기 때문에 같은 모델 내에서 존재하는 값을 기준으로 결측치를 보완

```
#   Column          Non-Null Count  Dtype
---  -
0   Name             6197 non-null   object
1   Location          6197 non-null   object
2   Price            6197 non-null   float64
3   Year             6197 non-null   int64
4   Kilometers_Driven 6197 non-null   int64
5   Fuel_Type        6197 non-null   object
6   Transmission      6197 non-null   object
7   Owner_Type       6197 non-null   object
8   Mileage          6132 non-null   float64
9   Engine           6166 non-null   float64
10  Power            6085 non-null   float64
11  Seats            6161 non-null   float64
dtypes: float64(5), int64(2), object(5)
```


3) 대체

나머지 결측값들은 평균값으로 대체

```
#   Column          Non-Null Count  Dtype
---  -
0   Name             6197 non-null   object
1   Location          6197 non-null   object
2   Price            6197 non-null   float64
3   Year             6197 non-null   int64
4   Kilometers_Driven 6197 non-null   int64
5   Fuel_Type        6197 non-null   object
6   Transmission      6197 non-null   object
7   Owner_Type       6197 non-null   object
8   Mileage          6197 non-null   float64
9   Engine           6197 non-null   float64
10  Power            6197 non-null   float64
11  Seats            6197 non-null   float64
dtypes: float64(5), int64(2), object(5)
```


4) 검증

결측값 존재 X




이상치 처리 : Box Plot

- Kilometers_Driven 의 Box Plot



이상치 제거 전



이상치 제거 후


1) Kilometers_Driven = 6500000 인 이상치 제거
제거 후 Box Plot으로 검증

```
df_raw[df_raw["Kilometers_Driven"] >= 6000000]
```

✓ 0.0s

	Name	Location	Price	Year	Kilometers_Driven	Transmi
2328	BMW	Chennai	99642.4	2017	6500000	

- Mileage 의 Box Plot




2) Mileage가 6.4 미만인 이상치 탐지
하지만 차종이 람보르기니이므로, 이상치 데이터가 아니라고 판단

```
df_raw[df_raw["Mileage"] <= 6.4] # 람보르기니이므로 연비 이상치 x , 연비는 이상치 없음
```

	Name	Location	Price	Year	Kilometers_Driven	Fuel_Type	Transmission	Owner_Type	Mileage
5781	Lamborghini	Delhi	183955.2	2011	6500	Petrol	Automatic	Third	6.4

- Seats 의 Box Plot



이상치 제거 후

3) Seats = 0 인
이상치 제거
제거 후 Box
Plot으로 검증

변수 정규성 검증 : 왜도 & 결정계수 이용

파생변수생성 1: 연간주행거리 (KilometerPerYear) = Kilometers_Driven / 차 나이 (car age = 2020 - year)


- 왜도 선출 코드

```
skew_values = df_raw_x.select_dtypes(include=['int64', 'float64']).skew()  
print(skew_values.sort_values(ascending=False))
```


kilometerPerYear	4.229057
Kilometers_Driven	4.159922
Power	2.017853
Seats	1.893742
Engine	1.467974
car_age	0.853421

왜도>1 인 변수 4개 설정: kilometerPerYear, Kilometers_Driven, Power, Seats
치우쳐진 데이터 분포로 추가적인 전처리 작업 필요
→ 분포의 비대칭성을 완화하기 위해 **로그 변환**을 적용


각 변수별 히스토그램을 통해 분포 변환 검증




추가적으로 모델을 구성하고,
결정계수 값의 비교(로그 변환 후 결정계수>로그 변환 전 결정계수) 를 통해 검증을 진행.




Seats 변수 로그 씌우기 전 후



Power 변수 로그 씌우기 전 후



Kilometers_Driven 변수 로그 씌우기 전 후



KilometerPerYear변수 로그 씌우기 전 후

파생변수 & 인코딩 설정

Owner_Type은 Ordinal Encoding, Transmission은 Binary Encoding을 적용하였으며,
Seats 기반 차량 크기(car_size)와 Location 기반 지역(Region) 및 인구 규모(population) 파생 변수를 생성하였다.

```
brand_price_mean = df_raw.groupby("Name")["Price"].mean()
df_raw["Brand_Price_Mean"] = df_raw["Name"].map(brand_price_mean)

bins = [0, 7000, 10000, 20000, 50000, np.inf]
labels = ["초저가형", "저가형", "중간", "고가형", "초고가형"]

df_raw["Brand_Tier"] = pd.cut(df_raw["Brand_Price_Mean"], bins = bins, labels = labels)

df_raw = pd.get_dummies(df_raw, columns = ["Fuel_Type", "Brand_Tier", "Region"], drop_first = True)
df_raw.drop(["Brand_Price_Mean"], axis = 1, inplace = True)
df_raw.head()
```

차량 모델(Name)별 평균 가격을 계산하여 브랜드 가격 수준을 나타내는 Brand_Price_Mean 변수를 생성하고,
이를 가격 구간 기준으로 Brand_Tier 변수로 구분하였다.


이후 Fuel_Type, Brand_Tier, Region 변수에 대해 One-Hot Encoding을 적용하여 모델 학습에 사용할 수 있도록 수치형 변수로 변환하였다.

#	Column	Non-Null	Count	Dtype
0	Transmission	6196	non-null	int64
1	Owner_Type	6196	non-null	int64
2	car_size	6196	non-null	int64
3	population	6196	non-null	int64
4	Region	6196	non-null	int64
5	Brand_Tier	6196	non-null	int64
6	Name_Audi	6196	non-null	int64
7	Name_BMW	6196	non-null	int64
8	Name_Bentley	6196	non-null	int64
9	Name_Chevrolet	6196	non-null	int64
10	Name_Datsun	6196	non-null	int64
11	Name_Fiat	6196	non-null	int64
12	Name_Force	6196	non-null	int64
13	Name_Ford	6196	non-null	int64
14	Name_Honda	6196	non-null	int64
15	Name_Hyundai	6196	non-null	int64
16	Name_ISUZU	6196	non-null	int64
17	Name_Jaguar	6196	non-null	int64
18	Name_Jeep	6196	non-null	int64
19	Name_Lamborghini	6196	non-null	int64
...				
46	Fuel_Type_LPG	6196	non-null	int64
47	Fuel_Type_Petrol	6196	non-null	int64
dtypes: int64(48)				

인코딩 및 파생 변수 생성 이후 전체 변수 구조를 확인한 결과, 모든 변수가 수치형으로 변환되었으며 결측치 검증

EDA-3. Heatmap

차량 가격은
**Power(0.75),
Engine(0.64),
Transmission(0.58)**
높은 양의 상관관계




Year – car_age (-1.00)

→ 2020-year = car_age 이므로 상관관계는 반비례,
-1.00이 나온다.

이는 동일한 정보이므로 Data 분석에서 Year를 제거

Engine – Power (0.86)

→ 엔진 크기와 출력 사이에 높은 상관관계로
Data 분석에서 Engine 제거



EDA-4. Anova Analysis

```
groups = [df_raw[df_raw['Location'] == c]['Price'] for c in df_raw['Location'].unique()]  
f_stat, p_val = stats.f_oneway(*groups)  
print(f_stat, p_val)
```

```
39.69478996593951 1.4779824706069307e-76
```

p-value < 0.5 이므로 Location과 Price는 변수간 유의미한 관계이다.

```
groups = [df_raw[df_raw['Fuel_Type'] == c]['Price'] for c in df_raw['Fuel_Type'].unique()]  
f_stat, p_val = stats.f_oneway(*groups)  
print(f_stat, p_val)
```

```
230.22444629641348 1.2934406094229069e-141
```

```
groups = [df_raw[df_raw['Transmission'] == c]['Price'] for c in df_raw['Transmission'].unique()]  
f_stat, p_val = stats.f_oneway(*groups)  
print(f_stat, p_val)
```

```
3165.8011426733938 0.0
```

```
groups = [df_raw[df_raw['Owner_Type'] == c]['Price'] for c in df_raw['Owner_Type'].unique()]  
f_stat, p_val = stats.f_oneway(*groups)  
print(f_stat, p_val)
```

```
21.05736627860285 1.4408655813409302e-13
```

마찬가지로, 나머지 변수도 Price와 Anova 분석을 해본 결과 (Fuel_Type, Transmission, Owner_Type) 모두 p-value < 0.5 이므로 모두 Price와 유의미한 관계이다.

따라서 해당 변수들은 이후 가격 예측 모델 구축 시 중요한 설명 변수로 활용될 수 있다.

1.선형 회귀 Model

OLS 회귀분석 결과

OLS Regression Results

Dep. Variable:	Price	R-squared:	0.887
Model:	OLS	Adj. R-squared:	0.886
Method:	Least Squares	F-statistic:	806.5
Date:	Sun, 15 Mar 2026	Prob (F-statistic):	0.00
Time:	01:16:37	Log-Likelihood:	-917.50
No. Observations:	4337	AIC:	1921.
Df Residuals:	4294	BIC:	2155.
Df Model:	42		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
const	10.1181	0.303	33.406	0.000	9.524	10.712
Name_Audi	0.3109	0.036	8.698	0.000	0.241	0.381
Name_BMW	0.2350	0.036	6.583	0.000	0.165	0.305
Name_Bentley	-2.1580	0.285	-7.566	0.000	-2.717	-1.599
Name_Chevrolet	-1.3212	0.303	-4.358	0.000	-1.916	-0.727
Name_Datsun	-1.3113	0.315	-4.162	0.000	-1.929	-0.694
Name_Fiat	-1.2536	0.308	-4.064	0.000	-1.858	-0.649
Name_Force	1.656e-15	1.19e-16	-3.192	0.001	-2.67e-15	-6.39e-16
Name_Ford	-0.5813	0.095	-6.122	0.000	-0.767	-0.395
Name_Honda	-0.8928	0.197	-4.525	0.000	-1.280	-0.506
Name_Hyundai	-0.8879	0.197	-4.509	0.000	-1.274	-0.502

****추후, 모델링을 위한 데이터는 모두 train:test = 7:3으로 진행한다.****

모델이 Price 변동의 약 88.7%를 설명, 안정적 독립 변수들이 차량 가격을 매우 높은 수준으로 설명.

p-value < 0.05 이므로 전체 회귀모델은 통계적으로 유의하다.

```
r2: 0.8915990878741518
mse: 0.08196121712437279
rmse: 0.2862886954184059
mae: 0.1976690044364556
mape: 0.02170882353689089
```

모델 평가 결과 R² 값이 약 0.89로 높은 설명력
MAPE가 약 2.17%로 나타나 차량 가격을 높은 정확도로 예측하는 모델

Audi,BMW 차량은 양의 상관관계
나머지 차량은 음의 상관관계

다중공선성 검증

```
# 상수항 추가 함수
df_train_x_const=add_constant(df_train_x)
# df로 저장
df_vif=pd.DataFrame()
df_vif['variable']=df_train_x_const.columns
df_vif['VIF']=[variance_inflation_factor(df_train_x_const.values,i) \
              for i in range(df_train_x_const.shape[1])]

df_vif.sort_values("VIF",ascending=True).round(2)
```

	variable	VIF
0	const	0.000000e+00
55	Fuel_Type_LPG	1.170000e+00
10	Owner_Type	1.260000e+00
11	car_size	1.780000e+00
39	Name_Smart	2.050000e+00
9	Transmission	2.310000e+00
8	kilometerPerYear	2.360000e+00
2	Kilometers_Driven	3.110000e+00
53	Location_Pune	3.290000e+00
6	Seats	3.450000e+00
3	Mileage	4.210000e+00

일반적으로 VIF 값이 5 이하이면 다중공선성 문제가 없다고 판단하며, 10 이상일 경우 변수 간 상관관계가 높은 것으로 해석된다.

분석 결과 대부분 변수의 VIF 값이 1~4 수준으로 나타나 변수 간 상관관계가 크지 않은 것으로 확인되었다.

Fuel_Type_LPG, Owner_Type, car_size, Transmission 등의 변수는 낮은 VIF 값을 보여 독립적인 정보를 가지고 있는 것으로 판단된다.

2. Decision tree Model

[GridSearchCV를 이용한 최적 파라미터 결과]

```
best estimator model:  
DecisionTreeRegressor(criterion='friedman_mse', max_depth=10,  
                      max_features='sqrt', min_samples_split=18)  
  
best parameter:  
{'criterion': 'friedman_mse', 'max_depth': 10, 'max_features': 'sqrt', 'min_samples_leaf': 1, 'min_samples_split': 18}
```


max_depth=10, max_features='sqrt', min_samples_split=18가 최적의 파라미터로 도출되었다.

[평가 지표]

```
R2: 0.8422784881905565  
mse: 0.11925219835411016  
rmse: 0.3453291159953214  
mae: 0.24775125056420516  
mape: 0.027207698348291932
```

모델의 결정계수(R2)가 0.842로 높은 수치를 보였다.

[중요 변수 결과]



중요변수 결과(차례순)

- 1.Brand_Tier
2. car_age
3. Power
4. Transimissons
- 5.Name_Toyota

3. Random Forest Model

[GridSearchCV를 이용한 최적 파라미터 결과]

```
best estimator model:  
RandomForestRegressor(max_depth=10, min_samples_leaf=5, min_samples_split=10,  
                        random_state=1234)  
  
best parameter:  
{'max_depth': 10, 'min_samples_leaf': 5, 'min_samples_split': 10, 'n_estimators': 100}
```


max_depth=10, min_samples_leaf=5, min_samples_split=10, n_estimators=1000이 최적 파라미터로 도출

[평가 지표]

```
mse: 0.064713875421071  
rmse: 0.2543892203318981  
mae: 0.17747212045359118  
mape : 0.0194685308393241  
r2: 0.914410212915731
```

모델의 결정계수(R2)가 0.914로 높은 수치를 보였다.

[중요 변수 결과]



중요변수 결과(차레순)

1. Power
2. car_age
3. Brand_Tier
4. Mileage
5. Kilometers_Driven

4. Gradient boost Model

[GridSearchCV를 이용한 최적 파라미터 결과]

```
best estimator model:
GradientBoostingRegressor(max_depth=10, max_features='sqrt', min_samples_leaf=4,
                           random_state=1234)

best parameter:
{'criterion': 'friedman_mse', 'learning_rate': 0.1, 'max_depth': 10, 'max_features': 'sqrt', 'min_samples_leaf': 4}
```


learning_rate=0.1, max_depth=10, max_features='sqrt', min_samples_leaf=4가 최적의 파라미터로 도출되었다.

[결과]

```
R2: 0.925416268257206
MSE: 0.05639226932168466
MAE: 0.1566512564049677
RMSE: 0.2374705651690008
MAPE: 0.017156681544388295
```

모델의 결정계수(R2)가 0.925로 높은 수치를 보였다.

[중요 변수 결과]



중요변수 결과(차례순)

- 1.Power
- 2.car_age
- 3.Brand_Tier
- 4.Transmission
- 5.Mileage

[중요 변수 결과]

5. XGboost Model

[GridSearchCV를 이용한 최적 파라미터 결과]

```
from xgboost import XGBRegressor
from sklearn.model_selection import GridSearchCV
xgb_model = XGBRegressor(random_state=1234)
param_grid = {
    'n_estimators': [50,60,70,80,90,100,110,120,130,140,150],
    'learning_rate': [0.01,0.05,0.1,0.3,0.5,0.7,0.9],
    'max_depth': [1,3,5,7,9,11,13],
}

grid_xgb = GridSearchCV(
    estimator=xgb_model,
    param_grid=param_grid,
    cv=3,
    scoring='r2',
    n_jobs=-1
)

grid_xgb.fit(df_train_x[selected_variable], df_train_y)
print("최적 파라미터:", grid_xgb.best_params_)
print("최고 평균 R² (Train):", grid_xgb.best_score_)
xgb_y_pred = best_model.predict(df_test_x[selected_variable])
print("최종 Test R²:", r2_score(df_test_y, xgb_y_pred))
```

✓ 1m 45.3s

최적 파라미터: {'learning_rate': 0.1, 'max_depth': 5, 'n_estimators': 150}


최고 평균 R² (Train): 0.9050945842624752

최종 Test R²: 0.9310267454385337

learning_rate=0.1,
max_depth=5,
n_estimators=150
최적 조합

**결정계수 R²는 약 0.93의
모델 중 최고의 성능**

[중요 변수 결과]




중요변수 결과(차례순)


1. Power
2. Transmission
3. Brand_tier
4. car_age
5. Name_Toyota

Comparing Models


RMSE Comparison




MAE Comparison



MAPE Comparison



MSE Comparison





여러 모델의 성능을 비교한 결과
MAPE, MSE, RMSE, MAE 등 평가 지표에
서 XGBoost 모델이 가장 낮은 오차

따라서 최종 Best Model is

XG Boost

Key Factor Extraction



Gradient Boost 모델의 변수 중요도 분석 결과
Power, car_age, Engine, Brand_Tier, Year 변수가
차량 가격 예측에 가장 큰 영향을 미치는 것으로 나타남.


Power 변수가 가장 높은 중요도를 보이며
차량 성능이 중고차 가격을 결정하는 핵심 요인.

핵심 인자 순위:

1. Power
2. Transmission
3. Brand_Tier
4. car_age
5. Name_Toyota

A4조의 Insight


차량 모델의 출시년도(year) 정보를 이용해 파생했던 car_age 변수를 차량의 연식 분포가 지역별로 어떻게 다른지 확인하고자 하였다. 이를 통해 지역마다 어떤 연식대 차량이 많이 거래되는지 파악하여 시장 특성을 분석하였다.



지역별 마케팅 전략

1. "신차급 매물 특화 지역" (평균 car_age가 낮은 지역 - 예: Kochi, Coimbatore 등)
해당 지역은 소비자들이 차를 빨리 바꾸는 경향이 있다.
→ 신차급 보증 매물 위주로 판매 전략 수립:
가격이 조금 높더라도 상태가 완벽한 3~5년 내외의 차량을 집중 배치하는 것이 유리
2. "실용적 가성비 특화 지역" (평균 car_age가 높은 지역 - 예: Kolkata, Pune 등)
해당 지역은 소비자들의 고연식 차량을 선호하는 경향이 있다.
이는 소비자들이 차를 한 번 사면 오래 타거나, 저렴한 중고차를 찾는 수요가 많음을 의미하므로
→ 가성비 매물의 박리다매 전략 수립 :
연식은 좀 되었어도 주행 성능에 문제가 없는 7~10년 차 차량들을 대량 확보 및 집중 배치

Takeaway



김성준:

데이터를 직접 분석해보니 막연하게 생각했던 중고차 시장이 아니라, 실제 수치와 변수 관계를 통해 시장의 흐름을 이해할 수 있다는 점이 인상 깊었다. 데이터를 통해 현실의 시장을 해석할 수 있다는 경험이 가장 의미 있었다.

박예인:

처음에는 단순히 가격을 예측하는 프로젝트라고 생각했지만, 분석을 진행할수록 변수 간 관계와 패턴을 찾는 과정 자체가 흥미롭게 느껴졌다. 데이터를 통해 숨겨진 특징을 발견하는 과정이 인상적이었다.

김어진:

데이터 분석은 단순히 모델을 만드는 것이 아니라 데이터를 이해하는 과정이라는 점을 배울 수 있었다. 데이터를 여러 관점에서 바라보며 해석하는 것이 중요하다는 것을 느꼈다.

박정현:

데이터를 기반으로 결과를 도출하는 과정에서 직관이 아닌 근거를 통해 판단하는 방법을 배울 수 있었다. 분석 결과를 통해 객관적인 의사결정을 할 수 있다는 점이 의미 있었다.

조수원:

이번 프로젝트를 통해 데이터 분석이 단순한 기술이 아니라 실제 시장과 문제 해결에 활용될 수 있는 도구라는 것을 느꼈다. 데이터를 통해 새로운 인사이트를 도출하는 과정이 흥미로웠다.

아쉬운 점: 분석 결과를 시각화 자료로 더 다양하게 표현했다면 전달력이 더 높아졌을 것 같다는 아쉬움이 남았다

변수 Excel 표

변수	변수설명	변수역할	변수형태	분석 제외사유	탐색적 기법			모델링 기법						중정	선정 (사유)
					그래프	검정	상관 분석	회귀 분석	DT	RF	GB	...	사례 연구		
Price	중고차 가격 중고차 가격 (단위: 천원)	목표변수	연속형												
Name	자동차의 브랜드와 모델	설명변수	연속형			○		○				○		3	○
Location	자동차를 팔거나 구매할 수 있는 위치	설명변수	범주형			○		○						2	대도시와 중소도시 간의 경제력 차이로 가격 편차가 있 을 것으로 예상되어 추가
Year	모델의 년도 혹은 버전	설명변수	연속형	car_age로 대체											
Kilometers_Driven	이전 소유주의 차량 주행거리(Km)	설명변수	연속형						○	○	○			3	○
Fuel_Type	자동차의 사용 연료의 종류	설명변수	범주형									○		1	
Transmission	자동차의 사용 변속기의 종류	설명변수	범주형				○	○				○		3	○
Owner_Type	소유권이 직접 소유인지, 중고 소유인지 여부	설명변수	범주형					○						1	
Mileage	자동차 회사가 제공하는 표준 주행거리(kmpl)	설명변수	연속형				○		○	○	○			4	○
Engine	엔진의 배기량(cc)	설명변수	연속형	Power와 높은 상관관 계(0.86)이므로 제거											
Power	엔진의 최대 출력(bhp)	설명변수	연속형		○		○	○	○	○	○	○		6	○
Seats	차의 좌석 수	설명변수	연속형					○						1	
New_Price	뉴모델의 가격	설명변수	연속형	결측치가 86% 넘음 으로 제거											
car_age	자동차의 출고 년수	파생변수	연속형				○		○	○	○			4	○
Region	지역의 구분(동/서/남/북)	파생변수	범주형					○						1	
kilometerPerYear	연간주행량	파생변수	연속형					○						1	
Brand_Tier	자동차 브랜드 등급	파생변수	범주형						○	○	○	○		4	○
population	지역 인구수 분포	파생변수	범주형												
car_size	차량 크기	파생변수	범주형					○						1	

감사합니다.